HW3 Report

資管碩一 R06725053 韓宏光

1. Basic Performance

(1) Describe your Policy Gradient & DQN model

a. Policy Gradient：

Policy Gradient為基於神經網路的模型，輸入為observation，輸出便是action(也可為該action的發生機率)。Policy Gradient透過分析一盤遊戲中結果的好壞(贏/輸)來識別在一盤遊戲裡action的好壞，並將這盤贏的**action視為是好的**，並提升所做**action的發生機率**；反之亦然。這讓Policy Gradient得到一個target function讓其根據每盤當下的observation最大化它認為最好的一步。

b. Deep Q Learning, DQN：

DQN具有以下3大結構特性：

(1) **Neural network**：以一個target function來**取代table**。

(2) **Replay memory**：**存儲過往與環境互動的記憶**，供之後訓練時隨機抽樣使用

(3) **Independent target network**：解藕online network訓練時與**其自身的相依性**。

DQN透過**分析一個observation來決定所有可能action的Q value**(由target network評估)，再根據這些Q value來決定要使用哪一個action。

DQN也藉由降低現實(environment給予的feedback加上受其影響的未來observation的reward)與預測(當時所做得Q value)的差距來訓練模型。

(2), (3) Plot the learning curve of your Policy Gradient on Pong & DQN on Breakout

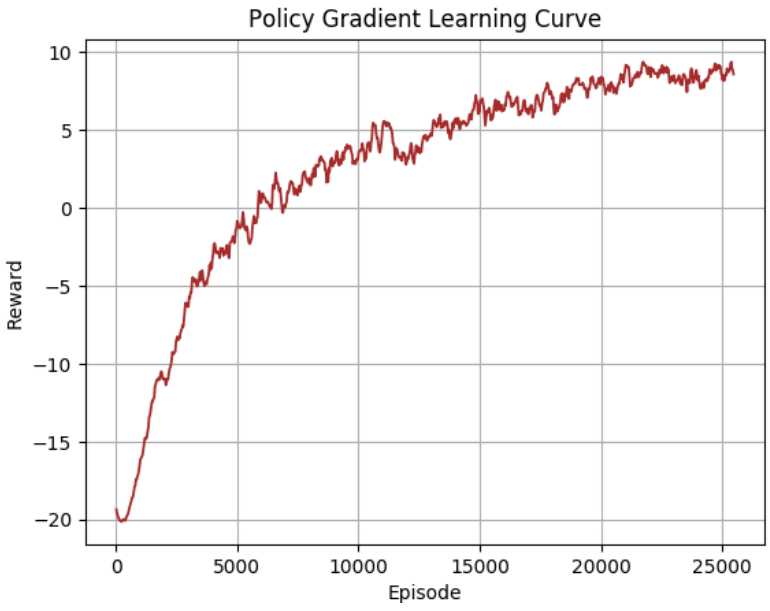

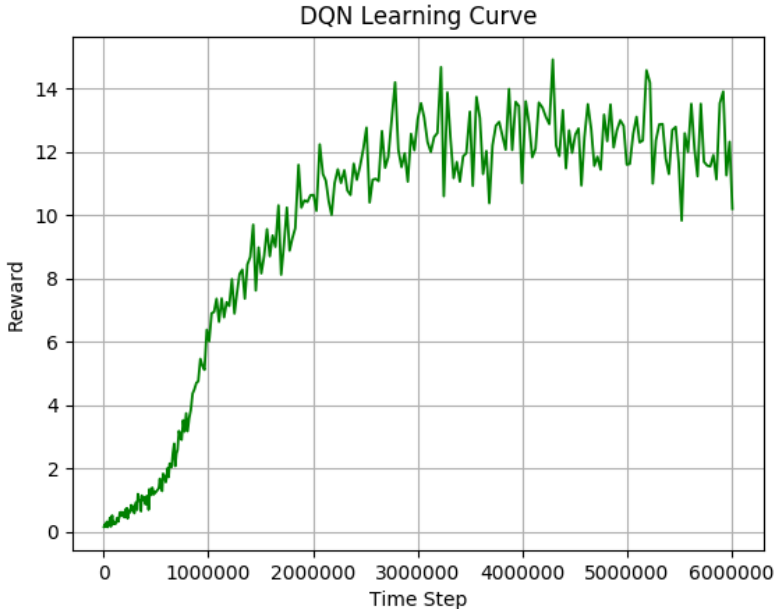

2. Experimenting with DQN hyper-parameters

(1) Plot all four learning curves in the same graph

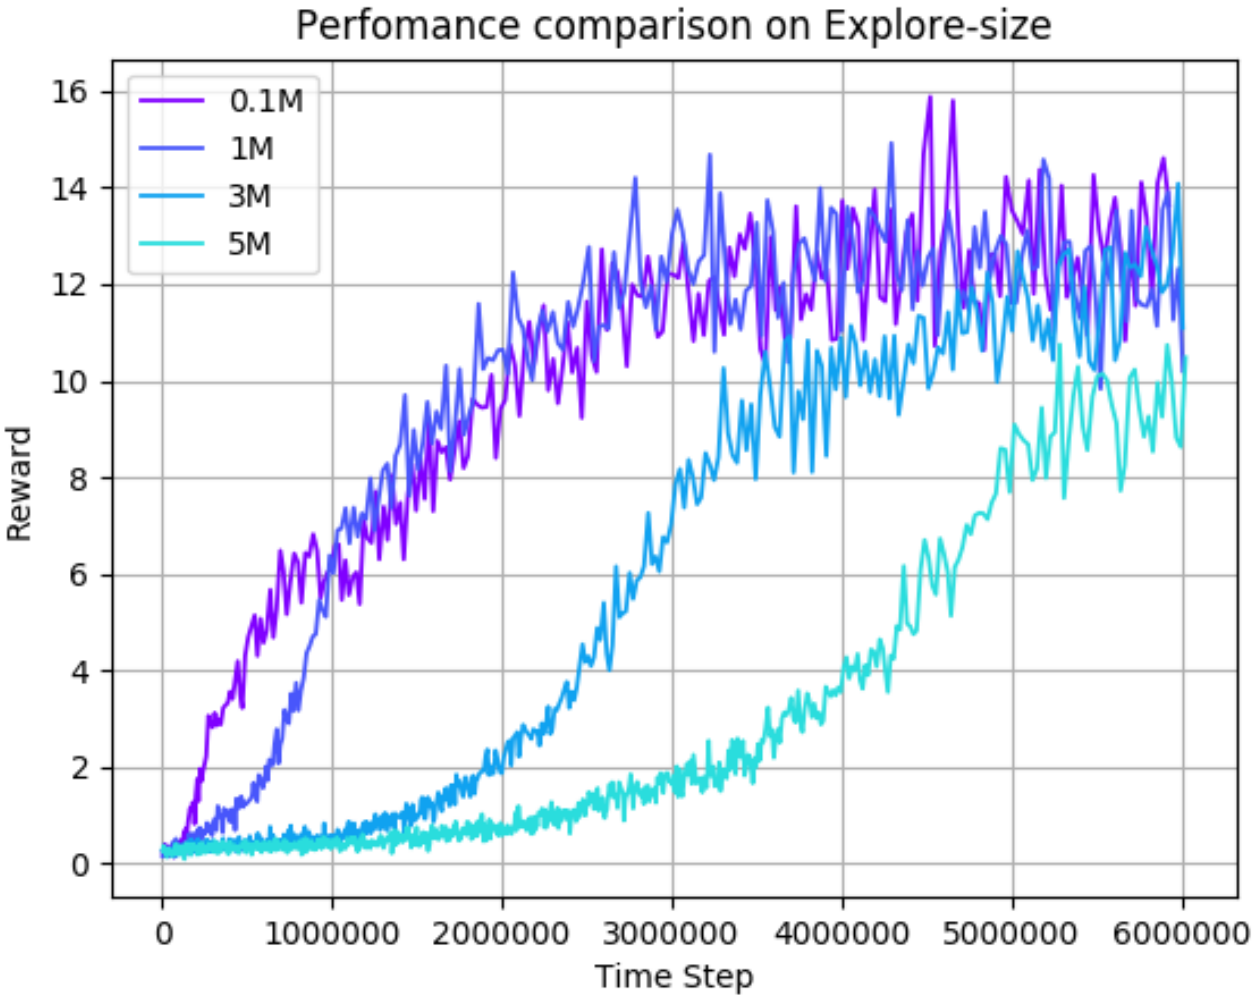

(2) Explain why you choose this hyper-parameter and how it effect the results

我的explore rate是根據**explore size線性下降**，而我認為一個適當且低的explore size可以更有效率地訓練模型。

在圖中可以得知**explore size調的越低，reward上升的越快**，且在explore size為10萬的前提下，最終結果的reward並不會差距太大。

但是當**explore size調高到一定程度**，不僅訓練速度慢，且在最終結果上也有一定的差距。

3. Bonus

(1) Improvements to Policy Gradient

a. Implement at least two improvements to Policy Gradient and describe why they can improve the performance

本作業實做Asynchronous Advantage Actor Critic, A3C，這會讓主機創建多個agent並行的環境，讓**多個有同樣結構的agent同時運算**，而這些並行的agent彼此並不互相干擾，並隨著訓練**非同步地更新著主agent中的參數**。簡單的說，這些從屬agent會從主agent那邊學習怎麼玩遊戲，再將各自玩遊戲遇到的feedback更新回主agent，而A3C採用的是輸出輸出動作的機率，即policy based，它在Q value的計算上**使用了優勢(Advantage)來評估，優勢指的是在同個state下每個action相對於其他的action的值相差**，舉例來說：假設狀態s的value為V，則優勢A即為Q(Q為在s的狀態下做出action的值)-V。

b. Plot a graph to compare and analyze the results with and without the improvements

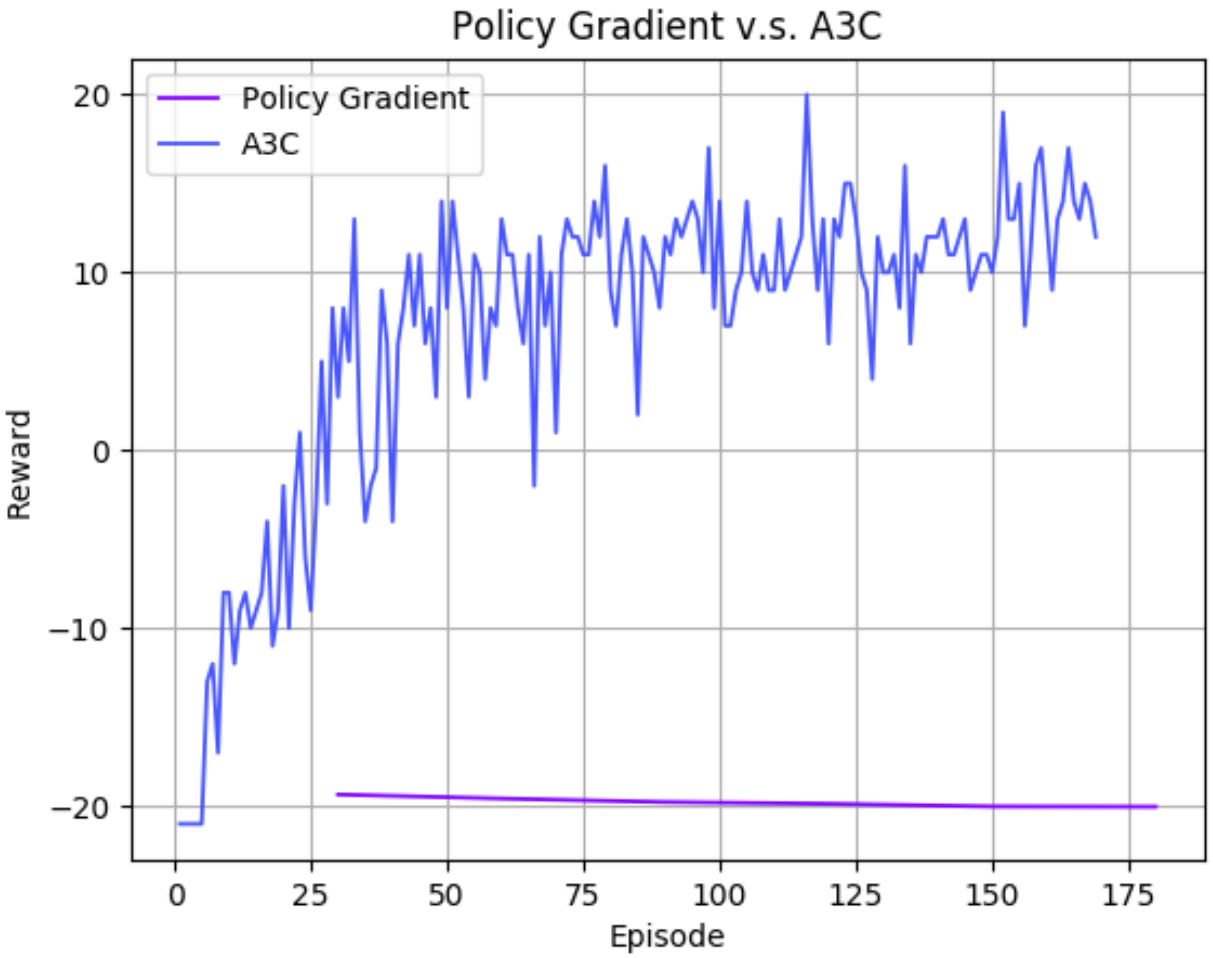

從上圖可以發現當A3C Train到約100個episode時，平均reward便已超過10，在同時期的policy gradient仍停留在-20得成績，由此可見A3C的Training效率非同小可。

(2) Improvements to DQN

a. Implement at least two improvements to DQN and describe why they can improve the performance

我實作了以下兩點：

(1) Double Q-Learning

因為原本的神經網路(online network)在**預測Qmax本來就有誤差**，這可能會導致對於每個state(observation)的**Q value的過度估計**。因此 Double Q-Learning引入**另一個獨立神經網路**來盡可能**消除這些最大誤差的影響**。而獨立神經網路即target network。

(2) Prioritized Replay memory

原本抽樣訓練的方法為**隨機抽樣**，但我們最希望訓練到的應該是那些**預測與現實落差最大的樣本**(如：玩breakout順利打了好幾十球)，但這些樣本再所有樣本數裡的佔比較低，應此為了使我們能經常取得這些「**珍稀**」的樣本，我們將**所有樣本按照預測與現實落差來進行排序**，並**調高這些「值得訓練的樣本」的抽樣機率**。

b. Plot a graph to compare and analyze the results with and without the improvements

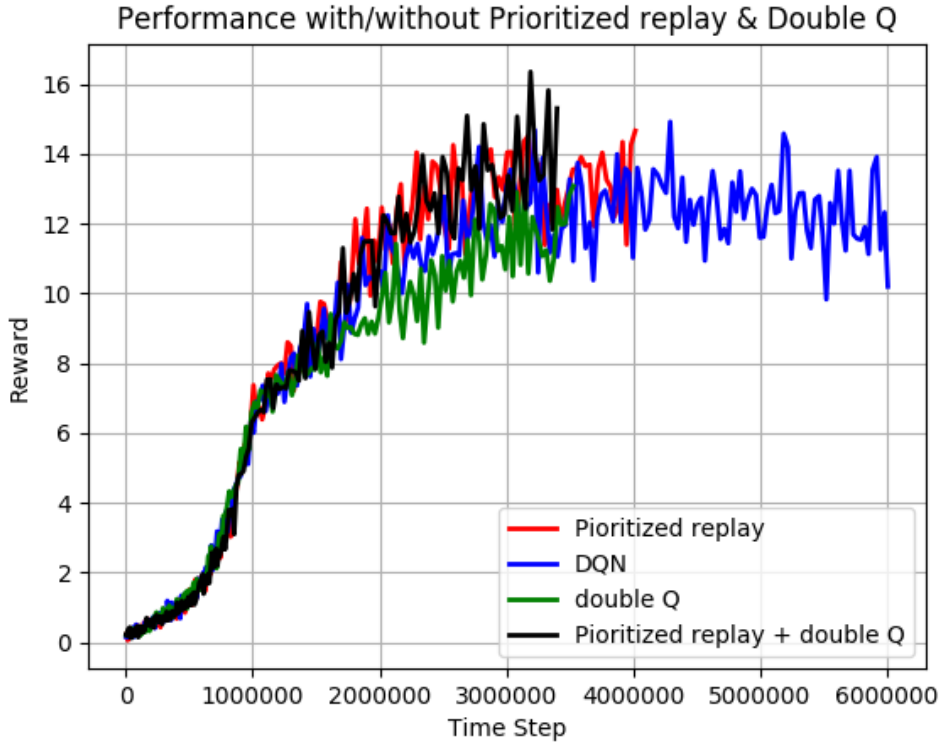

可以發現這些折線走向大多相同，但若仔細看，其實是有**明顯的「小落差」**(黑色平均高於綠、藍色1~2不等的reward)，會造成落差如此之小我認為主要有**兩個原因**：

(1) Memory size只有1萬，因此**原本sample到不錯的樣本的機率就不低**(若不錯的樣本佔1/100，考慮到32的batch size，則每次訓練抽到不錯的樣本的機率超過1/3)，因此做prioritized replay memory效益感覺不高，**若memory size變大很多，差距會更為明顯**。

(2) Double Q-Learning，主要是用來避免因為過度樂觀地估計Q值，使得找到的並非最佳解。而我改進後的Double Q-Learning最後有達到跟最初的Q Learning相同的表現；或許這代表**原本的模型便已經找到不錯的解**了。且Double Q-Learning是**在選擇多個action時的表現上會改善較多**，但本次作業僅4個action，因此進步的幅度不會太大。